

1. X 와 Y 가 독립적으로 구간 $(0, 1)$ 에서 균일분포(uniform distribution)를 따른다고 하자. 이로부터 U 와 V 가 다음과 같이 정의된다.

$$U = XY, \quad V = \frac{X}{Y}$$

1. (U, V) 의 결합밀도(joint density) 함수를 구하여라.
2. U 와 V 각각의 주변밀도(marginal density) 함수를 구하여라.

Solution:

1. 1개 이상의 변수가 존재하고, 그것들의 변환(transformation)으로 새로운 변수가 정의되었을 때 원래 알던 결합밀도함수에 자코비언만 곱하면 된다. 단, 원래 알던 결합밀도함수의 변수에 새로 정의된 변수를 대입해야 한다. 즉 $U = XY$ 이고 $V = X/Y$ 라면 U, V 의 결합밀도함수는 다음과 같이 정의된다.

$$f_{U,V}(u, v) = f_{X,Y}(x, y) \cdot |\det(J)|$$

원래 알던 변수 X, Y 를 새로 정의된 변수 U, V 로 표현하면 $X = U^{1/2}V^{1/2}$, $Y = U^{1/2}V^{-1/2}$ 이다. 고로 자코비언은

$$J = \begin{bmatrix} \frac{\sqrt{v}}{2\sqrt{u}} & \frac{\sqrt{u}}{2\sqrt{v}} \\ \frac{1}{2\sqrt{uv}} & -\frac{\sqrt{u}}{2}v^{3/2} \end{bmatrix}$$

이고 $|\det(J)| = 2^{-1}v^{-1}$ 이다.

$$0 < \sqrt{uv} < 1 \implies 0 < u < \frac{1}{v} \quad (1)$$

$$0 < \sqrt{\frac{u}{v}} < 1 \implies 0 < u < v \quad (2)$$

중요한 것은 범위인데 우리가 알고 있는 X 와 Y 의 범위를 이용하면 된다. 그리고 u 를 세로축 v 를 가로축으로 하여 부등식의 범위를 빗금으로 칠하면 그것이 U 와 V 가 이루고 있는 범위가 된다. 이 범위는 이중 적분할 때와 같이 한 부등식은 하나가 다른 하나에 의존할 것이고, 나머지 한 부등식은 그 변수가 독립적일 것이다. 그림은 생각하고 그러면 범위가 다음과 같다.

$$u < v < \frac{1}{u} \quad (3)$$

$$0 < u < 1 \quad (4)$$

그러므로 (U, V) 의 결합밀도함수는

$$f_{U,V}(u, v) = \frac{1}{2v}, \quad u < v < \frac{1}{u}, \quad 0 < u < 1$$

이다.

2. 위에서 구한 범위로 적분해 내면 된다. 다만 독립적이었던 변수를 의존적으로 바꿔주어야 한다. $0 < u < v^{-1}$ 과 $0 < u < v$ 둘이 있는데 이에 따라 v 의 범위가 달라진다. 그림을 그리면 쉽게 알 수 있다.

$$f_U(u) = \int_u^{1/u} \frac{1}{2v} dv \quad (5)$$

$$= -\ln u, \quad 0 < u < 1 \quad (6)$$

$$f_V(v) = \begin{cases} \int_0^v \frac{1}{2v} du = \frac{1}{2}, & 0 < v < 1 \\ \int_0^{1/v} \frac{1}{2v} du = \frac{1}{2v^2}, & 1 \leq v < \infty \end{cases} \quad (7)$$

2. Let X take on the values 0 and 1 with probabilities p and $1 - p$, respectively. It is known that $1/3 \leq p \leq 2/3$.

1. Find the MLE \hat{p} of p .
2. Find the expected squared error, $E(\hat{p} - p)^2$ of the MLE.
3. Show that the expected squared error of the MLE is uniformly larger than that of $\tilde{p} \equiv 1/2$.
That is, $E(\hat{p} - p)^2 > E(\tilde{p} - p)^2$ for all p .

Solution:

1. MLE라는 것이 내가 관측된 샘플을 가장 그럴듯하게 만들어주는 모수의 값을 고르는 것이므로, 만약 $X = 1$ 이라면 $1 - p$ 가 가장 높은 값을 \hat{p} 로 정할 것이다. 그 값은 알려진 바에 따르면 $1/3$ 일 것이므로 $\hat{p} = 1/3$ 이다. 반대로 관측된 것이 $X = 0$ 이라면 p 를 가장 높에 해야 하므로 그 값에 해당하는 $2/3$ 가 \hat{p} 일 것이다. 정리하면

$$\hat{p} = \begin{cases} 1/3, & \text{if } X = 1 \text{ (with prob=1-p)} \\ 2/3, & \text{if } X = 0 \text{ (with prob=p)} \end{cases}$$

2. 위에서 구한 것을 바탕으로

$$E(\hat{p} - p)^2 = E(\hat{p}^2 - 2p\hat{p} + p^2) \quad (8)$$

$$= \frac{1}{9}(1-p) + \frac{4}{9}p - 2p\left(\frac{1}{3}(1-p) + \frac{2}{3}p\right) + p^2 \quad (9)$$

$$= \frac{1}{2}\left(p^2 - p + \frac{1}{3}\right) \quad (10)$$

3. 2에서 이미 구했으므로 $\tilde{p} = 1/2$ 을 넣어 일단 부등식을 정리하자.

$$E(\hat{p} - p)^2 > E(\tilde{p} - p)^2 \implies -\frac{1}{36}(24p^2 - 24p + 5) > 0$$

p 의 범위가 $1/3$ 과 $2/3$ 사이이므로

$$f(p) = -\frac{1}{36}(24p^2 - 24p + 5)$$

이 최대가 되게 하는 정의역 $p = 1/2$ 를 사이에 두고 양옆으로 걸쳐있다. 즉 $1/3$ 과 $2/3$ 에서만 $f(p)$ 이 양수면 된다.

$$f\left(\frac{1}{3}\right) = \frac{1}{108} \quad (11)$$

$$f\left(\frac{2}{3}\right) = \frac{1}{108} \quad (12)$$

사실 위로 볼록이 포물선에서 $1/2$ 는 $1/3$ 과 $2/3$ 의 중간에 위치하므로 값이 같아지는 건 당연하다. 어쨌든 둘 다 양수이므로 증명 끝.

3. 다음의 확률 밀도 함수 (probability density function)를 갖는 확률변수를 고려하자.

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1.$$

1. 크기가 1 ($n = 1$)인 표본을 이용하여 다음의 가설을 검정하기 위한 $\alpha = 0.05$ 인 최강력 검정법 (the most powerful test)을 정의하시오.

$$H_0 : \theta = 1 \quad \text{vs} \quad H_1 : \theta = 2$$

2. $\theta = 2$ 인 경우, 1에서 정의된 검정법의 검정력(power)를 계산하시오.

Solution:

1. X 는 $\text{Be}(\theta, 1)$ 를 따른다. 가능도비를 계산하면

$$\frac{L_0}{L_1} = \frac{1}{2x} < k$$

이므로 기각역이 $c < X$ 이다. 상수 c 는 $\Pr(X > c | H_0) = \alpha$ 를 통해 알 수 있다.

$$\Pr(X > c | H_0) = \int_c^1 1 \, dx \quad (13)$$

$$= 1 - c = 0.05 \quad (14)$$

$$c = 0.95 \quad (15)$$

따라서 $X > 0.95$ 일 때 귀무가설을 기각하고 $X \leq 0.95$ 일 때는 귀무가설을 기각하지 않는 것이 최강력 검정법이다.

2. 검정력은 대립가설이 참일 때 귀무가설을 기각할 확률이므로 $\Pr(X > 0.95 | H_1)$ 이다.

$$\Pr(X > 0.95 | H_1) = \int_{0.95}^1 2x \, dx \quad (16)$$

$$= 1 - 0.95^2 \quad (17)$$

$$= 0.0975 \quad (18)$$

4. 다음과 같은 다중선형회귀모형

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$

을 고려하자. 여기서, Y 는 독립변수를, X_1, X_2, X_3 는 설명변수들을, 그리고 $\beta_0, \beta_1, \beta_2, \beta_3$ 는 회귀계수를 의미하며 ϵ 은 평균이 0, 분산이 σ^2 인 정규분포를 따르는 오차항을 의미한다. 모수에 대한 가설 $H_0 : \beta_1 = \beta_3$ 대 $H_1 : \beta_1 \neq \beta_3$ 를 고려하자. 유의수준 5% 하에서 이 가설을 검정하는 방법을 자세히 기술하시오.

Solution: 자세히 기술하라고 했으므로 정말 자세히 기술하도록 한다. 위와 같은 문제는 회귀계수에 제약조건을 주고 그것이 참인지 가설검정을 하는 법을 묻고 있다. 즉 $H : \mathbf{A}\beta = \mathbf{c}$ 와 같은 가설을 세운 것이다. 여기서 \mathbf{A}

β 의 각 행이 하나의 제약조건을 구성한다. 검정을 하기 위한 통계량은 당연히 $\mathbf{A}\hat{\beta}$ 이 될 것이고 그 값이 \mathbf{c} 와 너무 다르면 가설을 기각하게 된다. 여기서 너무 ‘다르면’의 기준을 정해야 하는데

그걸 제공해 주는 것이 바로 ‘거리’ 개념이다. 수학에서 거리 개념은 *distance function* 혹은 *metric* 을 통해 계산하게 되는데 집합의 두 원소를 아무렇게나 잡아도 거리를 계산해낼 수 있는 공간을 *metric space*라 부른다. 그리고 두 원소 사이의 거리뿐만 아니라 개별 원소의 ‘크기’도 계산해낼 수 있으려면 그 공간에 *norm*이 주어져야 한다. 여기서 $\mathbf{A}\hat{\beta} - \mathbf{c}$ 의 *norm*을 계산하면 그 거리가 될 것이다. 일반적으로 우리가 쓰는 크기의 개념은 ℓ_2 norm이라 부르고 유한한 벡터공간(finite vector space)에서는 ‘제곱합’꼴로 표현된다. 즉 벡터로 말하면 *quadratic form*이 되는 것이다.

따라서 $\mathbf{A}\beta - \mathbf{c}$ 의 제곱합은 $(\mathbf{A}\beta - \mathbf{c})'(\mathbf{A}\beta - \mathbf{c})$ 일 텐데 선형회귀에서는 각 추정량의 분산을 고려해주어야 한다. 즉 $\hat{\beta}$ 가 결정된 값이 아니라 관측 이전의 값이므로 각각의 원소가 \mathbf{c} 와의 거리를 계산할 때 얼마나 변하는지 고려하는 것이 상식적일 것이다. 따라서 우리가 정한 통계량과 검정하고 싶은 값 사이의 거리를 계산하기 위해 도출된 식은 다음과 같다.

$$(\mathbf{A}\hat{\beta} - \mathbf{c})' (\text{Var}(\mathbf{A}\hat{\beta}))^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c})$$

그리고 다음의 과정을 거쳐서 다시 계산된다.

- $\text{Var}(\mathbf{A}X) = \mathbf{A}\text{Var}(X)\mathbf{A}'$ (여기서 X 는 임의의 random vector)
- $\text{Var}(\hat{\beta}) = \text{Var}\left((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'y\right) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\sigma^2\mathbf{I}_n\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$
- 실제로 $\hat{\beta}$ 의 분산을 구할 때는 σ^2 를 모르므로 σ^2 의 비편향추정량인 $S^2 = \text{SSE}/(n - p - 1)$ 로 대체한다. 여기서 p 는 ‘predictor’의 앞글자로 설명변수의 개수를 의미한다. 절편까지 이미 추정한 모수의 개수가 $p + 1$ 이므로 자유도에서 그만큼 빠진다.

이렇게 되어 우리가 쓰게 될 검정통계량의 초기형태는 다음과 같다.

$$\frac{1}{S^2} (\mathbf{A}\hat{\beta} - \mathbf{c})' (\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}')^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c})$$

H 가 참일 때 구한 SSE을 SSE_H 이라 표시하고 다변량 정규분포의 특성을 이용하면 다음과 같은 사실이 구해진다.

- $\mathbf{A}\hat{\beta} \sim \mathcal{N}_q(\mathbf{c}, \sigma^2\mathbf{A}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{A}')$ (여기서 q 는 \mathbf{A} 의 행수)
- 위에서 구한 $\text{Var}(\mathbf{A}\hat{\beta})^{-1/2}$ 를 $\mathbf{A}\hat{\beta} - \mathbf{c}$ 앞에 곱해주면 $\mathcal{N}_q(\mathbf{0}, \mathbf{I}_q)$ 이 된다.
- 즉, 카이제곱분포가 표준정규분포를 따르는 확률변수의 제곱합꼴로 표시된다는 점을 상기해볼 때

$$(\mathbf{A}\hat{\beta} - \mathbf{c})' (\text{Var}(\mathbf{A}\hat{\beta}))^{-1} (\mathbf{A}\hat{\beta} - \mathbf{c}) \sim \chi^2(q) \quad (19)$$

임을 알 수 있다.

- 다음과 같은 사실이 성립한다. 증명은 Appendix로 뺀다.

$$\frac{\text{SSE}_H - \text{SSE}}{\sigma^2} = \left(\mathbf{A}\hat{\beta} - \mathbf{c} \right)' \left(\text{Var} \left(\mathbf{A}\hat{\beta} \right) \right)^{-1} \left(\mathbf{A}\hat{\beta} - \mathbf{c} \right) \quad (20)$$

- 따라서 $\text{SSE}/\sigma^2 \sim \chi^2(n-p-1)$ 이므로

$$F = \frac{(\text{SSE}_H - \text{SSE}) / (\sigma^2 q)}{\text{SSE} / (\sigma^2 (n-p-1))} \sim F_{q, n-p-1}$$

이제 문제로 다시 돌아가보자. 제약조건은 $\beta_1 = \beta_3$ 로 한 개이다. 따라서 \mathbf{A} 의 행은 1개, 즉 $q = 1$ 이다. 따라서

$$\mathbf{A}\beta = \begin{bmatrix} 0 & 1 & 0 & -1 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} = 0$$

이 된다. 그리고

$$F = \frac{\text{SSE}_H - \text{SSE}/1}{\text{SSE} / (n-4)} \sim F_{1, n-4}$$

를 따르고 $F > F_{1, n-4}^{-1}(0.05)$ 일 때 0.05 신뢰수준에서 귀무가설을 기각한다.

A SSE_H 유도

통계의 많은 문제는 최댓값/최솟값을 찾는 수치최적화 문제로 치환된다. 일반적인 선형회귀 모형은

$$Y = \mathbf{X}\beta + \epsilon$$

이며 위 모형을 적합할 때는

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} (Y - \mathbf{X}\beta)'(Y - \mathbf{X}\beta)$$

와 같이 최적화 문제로 바뀐다. 일반 선형회귀 모형을 적합하는 것은 제약조건이 없는 경우이지만 $\mathbf{A}\beta = \mathbf{c}$ 와 같은 제약조건 하에서 최소화하는 β 를 찾는 문제는 라그랑지 승수를 써서 해결한다. 제약조건이 있는 최적화 문제는 다음과 같이 표기한다.

$$\underset{\text{subject to } \mathbf{A}\beta=\mathbf{c}}{\min} (Y - \mathbf{X}\beta)'(Y - \mathbf{X}\beta)$$

라그랑지 승수를 써서 다시 문제를 쓰면 아래와 같다.

$$\mathbf{r} = (Y - \mathbf{X}\beta)'(Y - \mathbf{X}\beta) + \boldsymbol{\lambda}'(\mathbf{A}\beta - \mathbf{c}) \quad (21)$$

$$\hat{\beta}_H = \underset{\beta}{\operatorname{argmin}} \mathbf{r} \quad (22)$$

라그랑지 승수로 표현된 식을 최소화하는 방법은 정형화되어 있다. 먼저 정의역으로 정의된 변수로 미분을 하고 제약조건에 대입한 뒤에 나온 라그랑지 승수의 해를 원래 정의역으로 정의된 변수 식에 대입하는 것! 그러므로 \mathbf{r} 을 β 에 대해 미분하면

$$\frac{\partial \mathbf{r}}{\partial \beta} = -2\mathbf{X}'Y + 2\mathbf{X}'\mathbf{X}\beta + \mathbf{A}'\boldsymbol{\lambda} = \mathbf{0}$$

이 되고 $\hat{\beta}_H = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}'\hat{\boldsymbol{\lambda}}/2$ 이 도출된다. 이를 원래 제약 조건에 대입하면

$$\hat{\boldsymbol{\lambda}} = -2 \left(\mathbf{A} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}' \right)^{-1} (\mathbf{c} - \mathbf{A}\hat{\beta})$$

이 된다. 이제 $\operatorname{Var}(\mathbf{A}\hat{\beta})^{-1}$ 꼴이 등장한다. 이를 다시 $\hat{\beta}_H$ 의 식에 대입하면

$$\hat{\beta}_H = \hat{\beta} + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}' \left(\mathbf{A} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{A}' \right)^{-1} (\mathbf{c} - \mathbf{A}\hat{\beta}) \quad (23)$$

이 나온다. 이제부터 식이 좀 복잡해지는데 다시 $SSE_H - SSE$ 를 구하기 위해서는 다음과 같이 시작한다.

$$(Y - \mathbf{X}\hat{\beta}_H)'(Y - \mathbf{X}\hat{\beta}_H) = (Y - \mathbf{X}\hat{\beta} + \mathbf{X}\hat{\beta} - \mathbf{X}\hat{\beta}_H)'(Y - \mathbf{X}\hat{\beta} + \mathbf{X}\hat{\beta} - \mathbf{X}\hat{\beta}_H) \quad (24)$$

$$= \underbrace{(Y - \mathbf{X}\hat{\beta})'(Y - \mathbf{X}\hat{\beta})}_{SSE} + (\hat{\beta} - \hat{\beta}_H)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \hat{\beta}_H) + 2(Y - \mathbf{X}\hat{\beta})'(\mathbf{X}\hat{\beta} - \mathbf{X}\hat{\beta}_H) \quad (25)$$

$$= SSE + (\hat{\beta} - \hat{\beta}_H)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \hat{\beta}_H) + 2 \underbrace{(Y - \mathbf{X}\hat{\beta})' \mathbf{X} (\hat{\beta} - \hat{\beta}_H)}_{=0} \quad (26)$$

$$= SSE + (\hat{\beta} - \hat{\beta}_H)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \hat{\beta}_H) \quad (27)$$

여기서 저게 왜 0이 되냐하면 $\mathbf{X}'Y = \mathbf{X}'\mathbf{X}\hat{\beta}$ 이기 때문. 이제 (23)의 $\hat{\beta}$ 를 넘겨서 (27)에 대입하고 정리하면 샤샤샤 소거되고 (20)이 남는다.

B $SSE \sim \chi^2(n - p - 1)$

$Z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$ 이고 어떤 행렬 \mathbf{A} 가 $\mathbf{A}^2 = \mathbf{A}$ 를 만족한다고 하자(idempotent). 그러면 다음과 같은 성질을 만족한다.

- \mathbf{A} 의 고유값(eigenvalue)은 0 또는 1이다.
- $Z' \mathbf{A} Z \sim \chi^2(\text{Tr}(\mathbf{A}))$ 이다.

먼저 고유값이 0 또는 1인 사실은 다음을 통해 간단히 알 수 있다.

$$\mathbf{A}\lambda = \lambda v \quad (28)$$

$$\mathbf{A}^2 \lambda = \lambda \mathbf{A} v \quad (29)$$

$$(\text{LHS}) = \mathbf{A}\lambda = \lambda v \quad (30)$$

$$(\text{RHS}) = \lambda^2 v \quad (31)$$

$$\lambda^2 v = \lambda v \quad (32)$$

$$\therefore \lambda = 0 \text{ or } 1 \quad (33)$$