

1. 다음과 같은 다중선형회귀모형

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \epsilon$$

을 고려하자. 여기서, Y 는 독립변수를, X_1, \dots, X_p 는 설명변수들을, 그리고 $\beta_0, \beta_1, \dots, \beta_p$ 는 회귀계수들을 의미하며 ϵ 은 평균이 0, 분산이 σ^2 인 오차항을 의미한다.

- (a) 이 선형회귀모형을 적합한 후 얻어진 예측값을 \hat{Y} 으로 나타낼 때, \hat{Y} 의 기댓값 및 분산을 구하시오.
- (b) 이 회귀모형의 잔차(residual)를 $e = Y - \hat{Y}$ 으로 나타낼 때, e 의 기댓값 및 분산을 구하시오.
- (c) 잔차제곱합(residual sum of squares)의 기댓값을 구하시오.

Solution:

- (a) 행렬꼴로 바꾸면 쉽다.

$$E(\hat{Y}) = E(\mathbf{X}\hat{\beta}) \quad (1)$$

$$= \mathbf{X}\beta \quad (2)$$

$$\text{Var}(\hat{Y}) = \text{Var}(\mathbf{X}\hat{\beta}) \quad (3)$$

$$= \mathbf{X}\text{Var}(\hat{\beta})\mathbf{X}' \quad (4)$$

$$= \sigma^2 \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \quad (5)$$

- (b) 이미 구해봤으니 더 쉽다.

$$E(Y - \hat{Y}) = \mathbf{X}\beta - \mathbf{X}\beta \quad (6)$$

$$= 0 \quad (7)$$

$$\text{Var}(Y - \hat{Y}) = \text{Var}((\mathbf{I} - \mathbf{H})Y) \quad (8)$$

$$= (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})' \quad (9)$$

$$= \sigma^2(\mathbf{I} - \mathbf{H}) \quad (10)$$

(c) 잔차제곱합의 기댓값은 다음과 같다.

$$(Y - \mathbf{H}Y)'(Y - \mathbf{H}Y) = Y'(\mathbf{I} - \mathbf{H})Y \quad (11)$$

$$= (Y - \mathbf{X}\beta)'(\mathbf{I} - \mathbf{H})(Y - \mathbf{X}\beta) \quad (12)$$

$$= \epsilon'(\mathbf{I} - \mathbf{H})\epsilon \quad (13)$$

$$E(\epsilon'(\mathbf{I} - \mathbf{H})\epsilon) = \text{Tr}((\mathbf{I} - \mathbf{H})E(\epsilon\epsilon')) \quad (14)$$

$$= \sigma^2(\text{Tr}(\mathbf{I}) - \text{Tr}(\mathbf{H})) \quad (15)$$

$$= \sigma^2(n - p - 1) \quad (16)$$

여기서 중요한 것은 (11)에서 (12)로 넘어갈 수 있느냐 없느냐이다. (12)를 전개하면 (11)을 제외한 나머지 항들은 모두 소거되어 없어진다.

2. Suppose that the conditional distribution of X given that $P = p$ has a binomial distribution with parameters 5 and p , $X | P = p \sim \text{Bin}(5, p)$ and the marginal distribution of P is a uniform distribution on $(0, 1)$, $P \sim \text{Unif}(0, 1)$. We would like to calculate the correlation coefficient between X and P .

- (a) Compute variance of X .
- (b) Compute covariance of X and P .
- (c) Compute $\text{Cor}(X, P)$.

Solution:

- (a) 또 베이지언 문제다. 개인적인 생각에 이번 연도 문제는 최태련 교수님이 출제하신 것 같다. 보면 알 수 있다. 아무튼 이 문제는 분산의 분해에 대해 묻고 있는 것이다.

$$\text{Var}(X) = \text{Var}(E(X | P)) + E(\text{Var}(X | P)) \quad (17)$$

따라서 $E(X|P) = 5P$, $\text{Var}(X|P) = 5P(1-P)$ 이므로

$$\text{Var}(X) = \text{Var}(5P) + E(5P(1-P)) \quad (18)$$

$$= 25\text{Var}(P) + 5(E(P - P^2)) \quad (19)$$

$$= \frac{25}{12} + 5 \times \left(\frac{1}{2} - \left(\frac{1}{12} + \left(\frac{1}{2} \right)^2 \right) \right) \quad (20)$$

$$= \frac{35}{12} \quad (21)$$

(b) 분산에 이어 기댓값에서도 비슷한 법칙이 있다. *The law of double expectation*이라 하여 조건부를 걸어준 것을 두번 기댓값을 취하면 조건부 없는 것의 기댓값과 같아진다는 정리이다.

$$E(XP) = E(E(XP|P)) \quad (22)$$

베이지언 문제에서 무엇의 기댓값을 물어본다거나 하면 (a)에서 나온 ‘분산의 분해(variance decomposition)’와 ‘이중기댓값의 정리’를 잘 쓸 줄 알아야 한다.

$$\text{Cov}(X, P) = E(XP) - E(X)E(P) \quad (23)$$

$$= E(E(XP|P)) - E(X)E(P) \quad (24)$$

$$= E(P \cdot E(X|P)) - E(E(X|P))E(P) \quad (25)$$

$$= E(5P^2) - E(5P) \times \frac{1}{2} \quad (26)$$

$$= 5 \left(\frac{1}{12} + \left(\frac{1}{2} \right)^2 \right) - \frac{5}{4} \quad (27)$$

$$= \frac{5}{12} \quad (28)$$

(c) 위에서 필요한 요소를 다 구했다.

$$\text{Cor}(X, P) = \text{Cov}(X, P) / \left(\sqrt{\text{Var}(X) \text{Var}(P)} \right) \quad (29)$$

$$= \frac{5}{12} / \left(\sqrt{\frac{35}{12} \cdot \frac{1}{12}} \right) \quad (30)$$

$$= \frac{\sqrt{35}}{7} \quad (31)$$

3. Let X_1, X_2, \dots, X_n ($n > 2$) be a random sample from the following density

$$f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, 0 < \theta < \infty \\ 0, & \text{elsewhere} \end{cases}$$

- (a) Find the maximum likelihood estimator (MLE) $\hat{\theta}$ of θ .
 (b) Compare variance of $\hat{\theta}$ with the Cramér-Rao lower bound.

Solution:

- (a) 위 분포는 $\text{Be}(\theta, 1)$ 이다. 이 분포의 MLE를 여러 번 구해봤다면 $(-\sum \ln X_i)^{-1}$ 이라는 것을 알겠지만 그래도 구해보자.

$$L(\theta | \{X_i\}_{i=1}^n) = \theta^n \left(\prod_{i=1}^n X_i \right)^{\theta-1} \quad (32)$$

$$\ell(\theta | \{X_i\}_{i=1}^n) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln X_i \quad (33)$$

$$\ell'(\theta | \{X_i\}_{i=1}^n) = \frac{n}{\theta} + \sum_{i=1}^n \ln X_i \quad (34)$$

$$\hat{\theta}^{\text{MLE}} = n / \left(-\sum_{i=1}^n \ln X_i \right) \quad (35)$$

베타 분포를 따르는 X 에 로그를 취한 $\ln X$ 는 취하는 값의 범위가 $(-\infty, 0]$ 이기 때문에 $-\ln X$ 로 뒤집어주면 감마분포를 따르게 된다. 따라서 그것의 역수꼴인 MLE는 *inverse-gamma distribution*을 따른다.

- (b) 피셔 정보량(*Fisher information*)을 구해야 한다.

$$\ln f(X | \theta) = \ln \theta + (\theta - 1) \ln X \quad (36)$$

$$\frac{d}{d\theta} \ln f(X | \theta) = \frac{1}{\theta} + \ln X \quad (37)$$

$$\frac{d^2}{d\theta^2} \ln f(X | \theta) = -\frac{1}{\theta^2} \quad (38)$$

$$\mathcal{I}(\theta) = -E_X \left(\frac{d^2}{d\theta^2} \ln f(X | \theta) \right) \quad (39)$$

$$= \frac{1}{\theta^2} \quad (40)$$

여기서 주의해야 할 점은 MLE는 비편향 추정량이 아니라는 것이다. *Cramér-Rao bound*는

추정량이 비편향인가 아닌가에 따라 바뀐다.

$$\text{CB}(\hat{\theta}) = \begin{cases} \text{Var}(\hat{\theta}) \geq \frac{1}{n\mathcal{I}(\theta)}, & \text{if } \hat{\theta} \text{ is unbiased} \\ \text{Var}(\hat{\theta}) \geq \frac{d}{d\theta} \text{E}(\hat{\theta}) / (n\mathcal{I}(\theta)), & \text{if } \hat{\theta} \text{ is biased} \end{cases} \quad (41)$$

우리가 구한 MLE는 분포가 다음과 같이 구해진다.

$$-\ln X_i \sim \text{Exp}(\theta) \quad (42)$$

$$-\sum_{i=1}^n \ln X_i \sim \text{Ga}(n, \theta) \quad (43)$$

$$1 / \left(-\sum_{i=1}^n \ln X_i \right) \sim \text{InvGam}(n, \theta) \quad (44)$$

$$n / \left(-\sum_{i=1}^n \ln X_i \right) \sim \text{InvGam}(n, n\theta) \quad (45)$$

$$\text{E}(\hat{\theta}^{\text{MLE}}) = \frac{n}{n-1} \theta \quad (46)$$

$$\text{Var}(\hat{\theta}^{\text{MLE}}) = \frac{n^2 \theta^2}{(n-1)^2 (n-2)} \quad (47)$$

이다. *Inverse gamma distribution*이 생소한 사람은 위키피디아에 검색해보길 권한다. 쉽게는 감마 확률변수에 역수를 취하면 inverse-gamma 확률변수가 된다. (여기서 모든 변수는 rate-parameter이다.) 아무튼 위에서 보는 것처럼 MLE는 편향되어 있으므로 CB 중 아래 써야 하며, 기댓값을 모수에 대해 미분하면 $n/(n-1)$ 이 되고 고로 *Cramér-Rao bound*는 다음과 같다.

$$\text{Var}(\hat{\theta}^{\text{MLE}}) \geq \frac{\theta^2}{n-1} \quad (48)$$

4. Let X_1, \dots, X_n be a random sample from the following probability density function(pdf),

$$f(x; \theta) = \theta/x^2, \quad 0 < \theta \leq x < \infty.$$

1. Find a sufficient statistic for θ .
2. Find the maximum likelihood estimator (MLE) of θ .
3. Find the method of moments estimator (MME) of θ .

Solution:

- (a) Support가 모수에 의존하므로 가능도함수를 쓸 때 이를 명시해주어야 한다.

$$L(\theta | \{X_i\}_{i=1}^n) = \prod_{i=1}^n \frac{\theta}{X_i^2} \cdot I_{(\theta, \infty)}(X_i) \quad (49)$$

$$= \theta^2 \left(\prod_{i=1}^n X_i^2 \right)^{-1} \cdot I_{(0, X_{(1)})}(\theta) \quad (50)$$

*Fisher-Neyman factorization theorem*에 따르면 $X_{(1)}$ 이 θ 에 대한 최소충분통계량이다(minimal sufficient statistic). 이 문제의 의도된 바는 최소충분통계량을 구하는 것이지만 그냥 충분통계량만 구하라고 하면 X_1, \dots, X_n 도 되고 $X_{(1)}, \dots, X_{(n)}$ 도 된다. 문제가 사실 잘못됐다.

- (b) 이 경우에는 미분을 써서 최대가능도추정량을 구할 수 없다. 왜냐하면 정의역이 모수에 의존하기 때문이다. 하지만 가로축을 θ , 세로축을 가능도함수($L(\theta | \mathbf{X})$)로 놓으면 θ 가 증가함에 따라 가능도함수 역시 단조증가한다. 따라서 θ 가 가장 클 때가 어디인지를 찾아야 한다. 정의역의 범위가 $0 < \theta \leq x$ 이므로 모든 X_i , $i = 1, \dots, n$ 과 비교해서 θ 가 작아야 하므로 그냥 가장 작은 $X_{(1)}$ 보다만 작으면 된다. 따라서 θ 가 가장 클 때는 $X_{(1)}$ 이다. $\hat{\theta}^{\text{MLE}} = X_{(1)}$
- (c) 이 경우 적률추정량은 존재하지 않는다. 왜냐하면 기댓값(1차 적률)이 존재하지 않기 때문이다.

$$E(X_1) = \int_{\theta}^{\infty} \frac{\theta}{x} dx \quad (51)$$

$$= \theta \ln x \Big|_{\theta}^{\infty} \quad (52)$$

$$= \infty \quad (53)$$

전년도 기출에서인가 언급했었지만 확률공간(probability space)과 같은 유한측도공간(finite measure space)에서는 *Hölder inequality*로 인해 $1 \leq p < q$ 일 경우 q 차 적률이 존재하면 그보다 작은 p 차 적률은 무조건 존재한다고 했다. 뒤집어 말하면 q 보다 작은 p 차 적률이 발산할 경우 q 차 적률은 자동적으로 함께 발산하게 되어 있다. 이 때문에 1차적률인 기댓값이 유한하지 않고 무한대로 발산하면 그보다 큰 모든 $n > 1$ 인 n 차 적률은 모두 무한대로 발산한다. 고로 그 어떤 적률추정량도 존재하지 않게 된다.

5. Let X_1, \dots, X_n be a random sample from the following probability density function (pdf),

$$f(x; \theta) = \theta e^{-\theta x}, \quad 0 < x < \infty,$$

where $\theta = \theta_0$ or $\theta = \theta_1$. We assume that known fixed numbers $\theta_1 > \theta_0$.

- (a) Explain the *Neyman-Pearson lemma* briefly.
- (b) Explain the most powerful (MP) test briefly.
- (c) Obtain the MP test for testing $H_0 : \theta = \theta_0$ versus $H_1 : \theta = \theta_1$ by the *Neyman-Pearson lemma*.

Solution:

- (a) Simple과 simple 가설을 비교하는 경우 다음과 같이 가능도비가 어느 상수 k 보다 작아지면 귀무가설은 기각된다.

$$\Lambda = \frac{L(\theta_0 | x)}{L(\theta_1 | x)} \leq k \quad (54)$$

- (b) 이때 $\Pr(\Lambda \leq k | H_0) = \alpha$ (여기서 α 는 신뢰수준) 이면 최강력 검정이라 부른다.

- (c)

$$\Lambda = \frac{\theta_0^n \exp(-\theta_0 \sum_{i=1}^n X_i)}{\theta_1^n \exp(-\theta_1 \sum_{i=1}^n X_i)} \quad (55)$$

$$= \left(\frac{\theta_0}{\theta_1}\right)^n \exp\left((\theta_1 - \theta_0) \sum_{i=1}^n X_i\right) \leq k \quad (56)$$

따라서 $2\theta \sum_{i=1}^n X_i \leq 2\theta k'$ 일 때 귀무가설이 기각되면 최강력 검정이 된다. 여기서 2θ 를 곱해준 이유는 카이제곱분포를 따르게 만들어주고자 함이다. 그냥 감마분포로 해도 무방하다.

$$\Pr\left(2\theta_0 \sum_{i=1}^n X_i \leq \chi_{2n}^2 (1 - \alpha)\right) = \alpha \quad (57)$$